L'impact des biais linguistiques et culturels des IA génératives dans un contexte professionnel multiculturel sous l'angle de la théorie de Sapir-Whorf : la nécessité de la gouvernance des données et de l'IA

John Borel TAGNE

Engagement éthique

JE CERTIFIE :

- Avoir rédigé personnellement ce mémoire.

- Avoir remis ce mémoire uniquement à l'IAE de Paris 1 Panthéon Sorbonne, dans le cadre du MBA Management et Data Science.

- Avoir mis en italique ou indiqué clairement tout texte inséré par « copier-coller » ou tout autre mode d'insertion (hors les textes en annexe)

- Ne pas avoir dépassé 20% du texte en copier-coller (ou texte inséré) dans la rédaction du mémoire (hors les textes en annexe)

- Ne pas avoir utilisé une IAG pour générer du contenu (ex : génération de contenus textuels, visuels, et autres activités éditoriales qui sont de la responsabilité de l'auteur). Les autres usages d'IA devront être mentionnés en méthodologie (ex : machine learning, text mining, etc.). Il n'est pas nécessaire de mentionner les usages d'IA servant uniquement à la correction (ex : grammaire, ponctuation, orthographe).

DATE :

SIGNATURE :

L'université de PARIS I - Panthéon Sorbonne n'entend donner aucune approbation ni improbation aux opinions émises dans le présent document ; ces opinions doivent être considérées comme propres à leurs auteurs

L'impact des biais linguistiques et culturels des IA génératives dans un contexte professionnel multiculturel sous l'angle de la théorie de Sapir-Whorf : la nécessité de la gouvernance des données et de l'IA

John Borel TAGNE
Johnborel91@gmail.com
Traducteur et chef de projet en reconversion professionnelle Data & IA

Résumé

Ce mémoire analyse l'impact des biais linguistiques et culturels des IA génératives sur la collaboration au sein d'équipes professionnelles multiculturelles. La question de recherche interroge comment ces biais, interprétés à travers la théorie de la relativité linguistique de Sapir-Whorf, affectent la collaboration, la communication, la performance et la confiance, et quelles en sont les implications pour l'entreprise et la gouvernance des données et de l'IA.

L'approche méthodologique est mixte, combinant une étude quantitative via des questionnaires en ligne (N=48) et une analyse qualitative d'entretiens semi-directifs avec des cadres (N=7). Cette double approche a permis de croiser les perceptions générales avec des retours d'expérience approfondis.

Les résultats révèlent que si l'impact direct perçu est faible, c'est grâce à un effort de compensation humaine constant mais sous-estimé. La contribution théorique consiste à appliquer l'hypothèse de Sapir-Whorf à la co-construction de sens entre l'humain et l'IA, montrant comment les modèles façonnent les interactions et affectent la collaboration. La pertinence de la recherche réside dans la mise en évidence d'un faible niveau d'acculturation des professionnels aux risques liés aux biais, soulignant l'urgence pour les entreprises de se doter de cadres clairs. Les implications pratiques mènent à la nécessité d'une gouvernance des données et de l'IA robuste pour sécuriser les usages.

L'originalité majeure de ce travail est de connecter la sociolinguistique, l'éthique de l'IA et le management stratégique, en traduisant une problématique théorique en une solution managériale concrète : un plan d'implémentation de la gouvernance pour réduire les risques tout en créant de la valeur.

Mots clés : IA générative, biais linguistiques et culturels, relativité linguistique, gouvernance Data et IA, management interculturel

How does Generative AI impact Multicultural Professional Collaboration: tackling Linguistic and Cultural Biases through the Lens of the Sapir-Whorf Theory and suggesting Guidelines for Data and AI Governance

John Borel TAGNE
Johnborel91@gmail.com
Translator & Translation Project Manager transitioning into Data & AI

Abstract

This dissertation analyses the impact of linguistic and cultural biases of generative AI on collaboration within multicultural professional teams. The research question examines how these biases, interpreted through the Sapir-Whorf hypothesis of linguistic relativity, affect collaboration, communication, performance, and trust, and what the implications are for businesses and for data and AI governance.

The methodological approach involves a mixed combination of quantitative study via online questionnaires (N=48) and qualitative analysis of semi-structured interviews with managers (N=7). This dual approach allowed for the cross-referencing of general perceptions with in-depth experiential feedback.

The results reveal that while the perceived direct impact is low, this is due to a constant but underestimated human compensation effort. The theoretical contribution consists of applying the Sapir-Whorf hypothesis to the co-construction of meaning between humans and AI, showing how the models shape interactions and affect collaboration. The relevance of the research lies in highlighting a low level of literacy among professionals regarding the risks associated with bias, emphasizing the urgent need for companies to establish clear frameworks. The practical implications lead to the necessity of robust data and AI governance to secure their use.

The main originality of this work is connecting sociolinguistics, AI ethics, and strategic management, by translating a theoretical problem into a concrete managerial solution, namely an action plan for governance to reduce risks while creating value.

Keywords: generative AI, linguistic and cultural bias, linguistic relativity, Data and AI governance, intercultural management

Table des matières

1. Introduction 5
2. Revue de littérature 6
   2.1 Qu'est-ce qu'un biais ? 6
   2.2 Biais culturels et linguistiques des LLM : tour d'horizon scientifique 7
   2.3 Présentation de la théorie de Sapir-Whorf 8
3. Étude empirique : méthodologie, résultats et discussion 10
   3.1 Approche méthodologique 10
      3.1.1 Délimitation du champ d'étude et de la population 10
      3.1.2 Collecte et analyse des données 10
      3.1.3 Hypothèses de recherche 11
   3.2 Synthèse des résultats des questionnaires en ligne 12
      3.2.1 Profil des utilisateurs et modalités d'usage 12
      3.2.2 Perception de la qualité et conscience des biais 12
      3.2.3 Impacts opérationnels et stratégies correctives 13
      3.2.4 Gouvernance des données et de l'IA 14
   3.3 Discussion 15
      3.3.1 Causes des biais 15
      3.3.2 Manifestations et impact 16
      3.3.3 Solutions 17
4. La gouvernance des données et de l'IA comme réponse aux biais 19
   4.1 Définition de la gouvernance 19
   4.2 L'humain au cœur du changement 20
   4.3 Rôles, responsabilités et technologies 22
   4.4 Proposition de mise en œuvre 23
5. Conclusion 24

1. Introduction

Les IA génératives sont de plus en plus à la mode et leur utilisation est plus que démocratisée de nos jours. Leur utilité a été avérée et éprouvée à plusieurs égards, dans des champs d'utilisation divers et variés. Toutefois, cela n'est pas sans susciter des questionnements quant à leur fiabilité. Elles restent des outils, produits de l'œuvre humaine, qui elle est, par définition, imparfaite. Les LLM en particulier, ressortent souvent clairement cette imperfection à travers la génération de contenus textuels mitigés, portant plus ou moins à équivoque. Ce phénomène a une explication bien connue aussi bien dans le monde de la recherche en IA que dans le monde technique des concepteurs et développeurs d'IA, qui se situe dans les biais que comportent ces outils. Dans un article publié en 2024 sur son site, SAP définit la notion de biais d'IA comme *« la discrimination systémique intégrée dans les systèmes d'IA, laquelle peut renforcer les biais existants, amplifier la discrimination, les préjugés et les stéréotypes. »*[1]

L'UNESCO dans son étude préliminaire sur l'éthique de l'IA de 2019 souligne : *« Les systèmes d'IA ont d'importantes implications pour l'égalité des genres, dans la mesure où ils peuvent refléter les préjugés sociétaux existants, avec le pouvoir de les exacerber. La plupart de ces systèmes sont construits à partir de séries de données reflétant le monde réel, et celui-ci peut être biaisé, inéquitable et discriminatoire ».* (UNESCO, 2019, 24) C'est donc dire que les effets des biais peuvent se propager dans le monde réel du fait de l'utilisation des IA, entraînant ainsi diverses conséquences possibles. De multiples cas souvent relayés dans la presse font état de ces conséquences, qui vont de la marginalisation culturelle[2][3] à la discrimination ethnique face aux prêts bancaires[4]. L'on observe également des cas de biais démographiques dans les systèmes de reconnaissance faciale de police[5][6]. Enfin, Amnesty International, à travers une série d'études, a exposé les déboires des algorithmes biaisés utilisés dans les systèmes de protection sociale au Danemark[7], aux Pays-Bas[8] et en France[9] ainsi que leurs effets sur les victimes, généralement, les plus défavorisés.

Notre travail entend donc questionner précisément les biais linguistiques et culturels des LLM et des outils de traduction automatique, et évaluer leur impact concret au quotidien au sein d'équipes multiculturelles ou multilingues en entreprise. En nous basant sur la théorie de la relativité linguistique de Sapir-Whorf, il s'agira précisément pour nous, de répondre à la problématique suivante : quel est l'impact des biais linguistiques et culturels des LLM et outils de TA, lorsqu'ils sont utilisés comme outils de communication au sein d'équipes multiculturelles ou multilingues, sur la collaboration, la performance, la perception de l'autre et la confiance au sein de l'équipe ? Et quelles en sont les éventuelles conséquences à plus grande échelle sur la réputation et les performances de l'entreprise ? Quelle implication pour la gouvernance des données et de l'IA ?

---

[1] https://www.sap.com/canada-fr/resources/what-is-ai-bias, consulté le 29/09/2025

[2] https://magazine.mindplex.ai/post/ais-linguistic-bias-a-silent-architect-of-cultural-marginalization, consulté le 12/06/2025

[3] https://venturebeat.com/ai/large-language-models-exhibit-significant-western-cultural-bias-study-finds/, consulté le 12/06/2025

[4] https://newsroom.haas.berkeley.edu/minority-homebuyers-face-widespread-statistical-lending-discrimination-study-finds/, consulté le 12/06/2025

[5] https://privacysos.org/blog/five-fast-facts-from-the-federal-study-of-demographic-bias-in-facial-recognition/, consulté le 12/06/2025

[6] https://www.aclu.org/news/privacy-technology/how-is-face-recognition-surveillance-technology-racist, consulté le 12/06/2025

[7] https://www.amnesty.fr/liberte-d-expression/actualites/les-algorithmes-des-systemes-de-protection-sociale-accentuent-les-discriminations#:~:text=L%27organisme%20danois%20de%20protection,de%20discriminer%20les%20personnes%20pr%C3%A9caires., consulté le 12/06/2025

[8] https://www.amnesty.org/fr/latest/news/2021/10/xenophobic-machines-dutch-child-benefit-scandal/ consulté le 12/06/2025

[9] https://www.amnesty.fr/liberte-d-expression/actualites/france-l-algorithme-de-la-caisse-nationale-des-allocations-familiales-cible-les-plus-precaire, consulté le 13/06/2025

Pour répondre à ces questions, nous allons structurer notre argumentaire comme suit : d'abord, un tour d'horizon sur les questions de biais de langue et de culture dans les LLM vu par la science ; puis, un cadrage méthodologique pour ancrer notre étude empirique, qui sera essentiellement qualitative ; et enfin, une discussion des résultats obtenus qui nous permettra de déboucher sur des propositions de solutions en vue de la réduction des biais dans les LLM et surtout, une meilleure maîtrise des données et des IA à travers une gouvernance robuste.

2. Revue de littérature

2.1 Qu'est-ce qu'un biais ?

L'université de Sherbrooke au Canada, dans son feuillet sur *Les biais inconscients*, établit la définition suivante : *« Un biais est un raccourci mental que notre cerveau prend involontairement et qui nous amène à porter automatiquement des jugements rapides, qui manquent d'impartialité et d'objectivité. »* Dans un style plus synthétique, Jenks (2024) résume : *« Bias is a preference for something or someone, which includes impartial beliefs and judgement ».* Ces deux définitions ressortent certains traits caractéristiques des biais, à savoir l'aspect involontaire et préférentiel, la rapidité de jugement et enfin l'impartialité et la subjectivité. Le ministère français de l'Éducation dans sa fiche outil sur les biais cognitifs, définit le biais cognitif comme *« un mécanisme de la pensée qui entraîne une déviation du jugement ».* Les études psychologiques recensent plus de 250 biais cognitifs (Mery 2022, Fasquelle 2023, Venturino 2023), résumés dans le codex des biais cognitifs ci-après, proposé par John Manoogian.

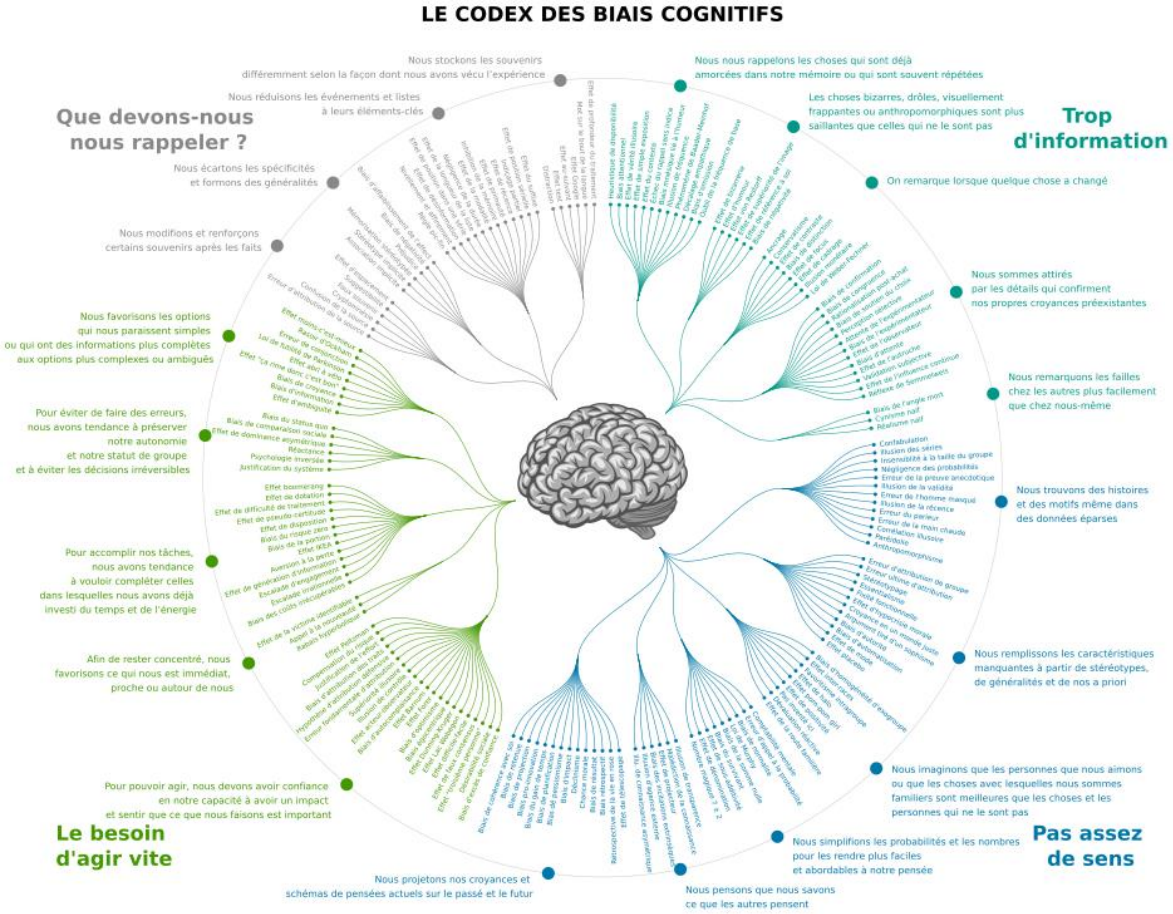

Fig. 1 : Codex des biais cognitifs

Dans le cadre du présent travail, nous nous attarderons sur les biais linguistiques et culturels, leurs causes et manifestations dans les outils d'IA, et plus particulièrement dans les LLM, et enfin les solutions d'atténuation de ces biais.

2.2 Biais culturels et linguistiques des LLM : tour d'horizon scientifique

Les rapports entre l'homme et les IA, et notamment les LLM, ont parsemé les études et publications scientifiques ces dernières années, du fait de l'essor de ces technologies et de leur évolution exponentielle dont l'impact dans notre quotidien n'est plus à démontrer. Ce faisant, la question des biais culturels dans les LLM a été traitée de fond en comble et sur différents aspects. Liu (2024) nus offre une vue panoramique intéressante de la littérature autour des biais linguistiques et culturels des LLM. Il en ressort notamment que les biais peuvent émerger à différents stages du développement des LLM : pendant l'annotation des données, la sélection des données d'entraînement, la conception de l'architecture du modèle ou encore dans la méthodologie de recherche (Liu 2024, reprenant Hovy and Prabhumoye, 2021; Sap et al., 2022). Bien que les LLM soient conçus pour pouvoir comprendre et respecter les normes culturelles de différentes communautés et, dans l'idéal, générer du texte qui reflète ces spécificités culturelles, ils ont plutôt tendance à reproduire les schémas culturels des pays occidentaux et développés : *« However, AI systems often reflect the cultural values of Western, Educated, Industrialized, Economically Affluent, and Democratic societies (Prabhakaran et al., 2022). Modern LLMs exhibit significant cultural bias, defaulting to Western culture and norms even when operating in non-Western languages. »* (id.). Les LLM auraient donc tendance à générer automatiquement des textes qui laissent entrevoir des manières de penser, de faire et même de parler, des cultures occidentales, et principalement anglo-saxonnes (plus précisément américaines). Par exemple, lorsque ChatGPT est interrogé en anglais, son algorithme le pousserait à restituer automatiquement du contenu basé sur la culture américaine, indique Z. Liu, qui poursuit en précisant que cela proviendrait certainement des biais intégrés dans les données d'entraînement (majoritairement en anglais USA) de ChatGPT. Liu (ibid.) rajoute, à titre d'explication : *« LLMs can inherit harmful and stereotypical language from their training data, leading to downstream representational harms (Blodgett et al., 2020). Additionally, they internalize, spread, and amplify toxic language (e.g., offensiveness, hate speech, and insults) and social biases (e.g., stereotypes towards people with a particular demographic identity) existing in the training corpora (Gehman et al., 2020; Sheng et al., 2021). »*

Jenks (2024) apporte une autre explication aux nombreux biais observés dans les LLM en invoquant le problème dit de la boîte noire (Black box problem), qui définit le mystère côté utilisateurs au sujet des algorithmes utilisés dans les LLM. Autrement dit, si les utilisateurs avaient une connaissance plus approfondie des algorithmes, règles, données et autres paramètres utilisés pour concevoir les LLM qu'ils utilisent, alors peut-être que l'on observerait moins de biais, car leur avis et suggestions permettraient de corriger les biais et erreurs des LLM. Mais, du fait du mystère qui plane autour du sujet et de l'inaccessibilité des algorithmes, les utilisateurs sont comme obligés d'utiliser aveuglément, ce qui pose pour l'auteur, un problème de confiance (trust) de la part des utilisateurs envers les LLM. Les biais sont donc source de manque de confiance chez les utilisateurs des LLM, et cela peut affecter leur utilisation ainsi que leur perception et leur intégration des résultats qu'ils génèrent : *« With little to no understanding of the algorithms that generate responses in ChatGPT and other similar programs, users must decide whether to trust the extent to which AI-LLM is fair, unbiased, and ethical (European Commission 2024) »* (Jenks 2024, 4).

Cependant, les biais algorithmiques des LLM ne reflètent que les biais culturels présents chez les humains qui les conçoivent et les développent, car ces derniers répercutent dans les algorithmes les préjudices, stéréotypes et constructions subjectives qu'ils nourrissent. Jenks (ibid.) cite à titre d'illustration une étude d'Obermeyer et al. (2019) qui démontre que les institutions de santé utilisent des algorithmes emprunts de biais racistes qui déterminent d'office les patients noirs comme étant plus problématiques et coûteux. Cet exemple fait parfaitement écho aux cas d'outils de reconnaissance faciale

aux USA mentionnés plus haut, ainsi qu'aux algorithmes des services sociaux en Serbie, aux Pays-Bas et en France, décriés par Amnesty International. E. Fleisig et al. (2024) ont étudié les différences en matière de biais linguistiques en anglais standard et non standard dans ChatGPT-3.5 et ChatGPT-4. Dans leur article, les chercheurs comparent 10 variantes d'anglais, à savoir l'anglais britannique standard, l'anglais américain standard et 8 variantes (Kenya, Nigéria, Écosse, Inde, Jamaïque, Singapour, Émirats Arabes Unis et Irlande). Il en ressort que les modèles de LLM ont tendance à basculer automatiquement vers l'anglais standard britannique ou américain dans les résultats qu'ils génèrent, minimisant voire effaçant ainsi les marqueurs culturels des autres variantes. Par ailleurs, lorsqu'ils sont interrogés dans les variantes d'anglais étudiées, les LLM ont tendance à générer des réponses empruntes de marqueurs culturels exagérés ou stéréotypés, selon les évaluations effectuées par des locuteurs natifs de ces variantes. Cet exemple montre une fois de plus que les LLM sont des transmetteurs des biais culturels et linguistiques qu'ils héritent toutefois de leurs créateurs.

Enfin, sur le plan politique, les LLM peuvent également véhiculer des biais entraînant de la manipulation d'information, voire de la désinformation. Steinert & Kazenwadel (2024) ont démontré cela en interrogeant ChatGPT-3.5 à propos du conflit israélo-palestinien et du conflit kurde en Turquie. L'étude démontre que le modèle a tendance à prendre parti dans lesdits conflits, en annonçant des taux de fatalité nettement inférieurs (34 ± 11%) lorsqu'il est interrogé dans la langue de l'assaillant, par rapport à une interrogation dans la langue de la victime. Il va même parfois jusqu'à nier l'existence de l'attaque faisant l'objet de la requête. Les auteurs soulèvent dans ce cas un double biais lié d'une part aux médias et à l'IA, d'autre part. En ce qui concerne les médias, le problème se situe au niveau des articles de presse écrite qui servent à entraîner GPT-3.5 sur le sujet des conflits politiques étudiés. Il se trouve que ces articles ont logiquement tendance à amplifier les chiffres dans les rapports d'attaques dans la langue des victimes. En outre, le fait que le LLM aille aussi puiser dans les contenus des réseaux sociaux, en dehors des articles de presse, a tendance à biaiser considérablement ses réponses, du fait des discours de haine qui pullulent ces plateformes (ibid.). De ce fait, les LLM, loin de faire preuve d'impartialité, peuvent donc, comme le montre ici GPT-3.5, être apparentés à des outils de propagande dans le cadre de conflits armés.

Urman & Makhortykh (2023) vont plus loin et démontrent que, dans certains cas, en fonction de l'objet de la requête, les LLM peuvent même quasiment refuser de répondre voire produire des réponses totalement fausses. La cause de ce comportement se trouve dans les règles protectrices (guardrails) intégrées dans les algorithmes des LLM, qui peuvent, en fonction des situations, être manipulées pour servir de censure ou encore (re)produire des biais politiques et afficher des performances plus ou moins efficaces en fonction de la langue dans laquelle est effectuée la requête (Steinert & Kazenwadel 2024, 3). Les chercheurs font état du cas de Google Bard, qui refuse de répondre à 94% des questions posées en langue russe au sujet du président russe, Vladimir Poutine, contre 34% pour Microsoft Bing et 26% pour ChatGPT. Enfin, les trois LLM ont tendance à injecter de fausses informations dans leurs réponses, à des degrés différents, et selon la langue (plus en russe et en ukrainien et moins en anglais), lorsqu'ils sont interrogés sur des personnalités et événements politiques en Russie, en Ukraine, en Chine et aux États-Unis.

Des erreurs linguistiques à la désinformation politique en passant par la prédominance culturelle, nous voyons que les biais des LLM peuvent avoir des manifestations diverses et variées. Avant d'aller plus loin dans leur manifestation concrète dans le quotidien des professionnels sur lesquels sera basée notre étude ainsi que les solutions mises en place par ces derniers et leurs entreprises, il convient à ce niveau de présenter le cadre théorique qui constituera l'ossature de notre travail.

2.3 Présentation de la théorie de Sapir-Whorf

Au début du 19e siècle, Willhelm von Humboldt, linguiste et théoricien politique allemand, consacre ses travaux aux relations entre la langue et la pensée. Bien plus que le simple fait de transmettre ce qui se passe dans notre esprit, la langue est, pour Humboldt, un miroir. Sur cette idée, il basera sa théorie de la langue comme vision du monde, en allemand « *Sprache als Weltansicht* ». Pour lui, la langue que nous

parlons nous permet de nous comprendre nous-mêmes et de comprendre le monde. Cette vision à la fois culturelle et anthropologique de la langue fait d'elle la loupe au travers de laquelle l'homme perçoit, analyse et adapte son rapport à lui-même, à autrui et au monde physique autour de lui. La théorie gagnera en popularité dans le monde scientifique à la fin du 19e siècle, notamment avec les travaux de Franz Boas, anthropologue américain d'origine allemande. Ce dernier s'aligne sur les pas de Humboldt, et axe ses travaux notamment sur les catégories grammaticales des langues, qui, selon lui, reflètent la façon dont notre culture classifie le monde. Pour Boaz, les langues classent la façon dont nous percevons le monde de manière différente et subconsciente.

La théorie prendra un tournant plus intéressant au début du 20e siècle en linguistique avec les apports d'Edward Sapir et de Benjamin Lee Whorf. Sapir va suivre Boaz en soutenant que les langues classent la manière dont nous percevons le monde. Toutefois, il souligne que les langues sont des systèmes complets, souvent intraduisibles entre eux[10]. Pour lui, la langue est nécessaire pour le développement intégral de la capacité à penser des humains, car celle-ci découle de la capacité à interpréter les langues qu'ils parlent. Parler des langues différentes amène donc des interprétations différentes, qui à leur tour imposent des contraintes sur les pensées.

Whorf, étudiant de Sapir, va finaliser cette théorie en apportant la contribution souvent décrite dans les sciences cognitives comme étant la plus marquante. Il ajoute principalement à l'idée de la langue comme vision du monde ou comme outil de modélisation culturelle du monde, la spécification selon laquelle toutes les catégories linguistiques ne sont pas manifestes et qu'il existe dans les langues des informations codées de façon implicite. De ce fait, même s'il s'aligne sur l'idée de Sapir, il ne trouve pas qu'il soit nécessaire d'utiliser activement notre langue pour pouvoir interpréter des choses à travers elle. C'est l'idée qui ressort de cette citation de Whorf reprise dans Haun et al. (2011) : « *Les utilisateurs de grammaires très différentes sont orientés par leurs grammaires vers des types d'observations différents et des évaluations différentes d'actes d'observation extérieurement similaires, et ne sont donc pas équivalents en tant qu'observateurs, mais doivent parvenir à des vues du monde quelque peu différentes* ».

L'hypothèse de Sapir et Whorf (ou théorie de Sapir-Whorf) affirme qu'une langue donnée affecte et reflète les actions et les pensées de ses locuteurs. La paternité de la théorie telle qu'on la connaît aujourd'hui est souvent attribuée à Whorf pour sa contribution majeure. Il a notamment énoncé deux hypothèses distinctes mais complémentaires dites hypothèse forte et hypothèse faible. L'hypothèse forte, ou théorie du déterminisme linguistique, veut que la langue que nous parlons détermine les pensées que nous pouvons avoir. Autrement dit, chacune des actions et pensées des humains est contrainte par leur langue d'expression. L'hypothèse faible quant à elle, stipule que la langue que nous parlons influence, mais ne détermine pas, les pensées que nous pouvons avoir. C'est la forme la plus acceptée aujourd'hui, baptisée théorie de la relativité linguistique (on trouve également relativisme linguistique). Une troisième hypothèse a même vu le jour au fil du temps et des recherches, selon laquelle la pensée ne serait plus uniquement forgée par la langue ; le langage (via l'acte de parole) serait également vecteur de transmission de biais culturels et linguistiques. Cette théorie au croisement de la sociolinguistique et de l'ethnolinguistique trouve des applications multiples et variées allant de l'apprentissage des langues, à l'enseignement des langues étrangères en passant par la traduction, les études interculturelles et même l'informatique. De nombreuses études ont corroboré et réfuté cette théorie, mais nous n'allons pas nous étendre sur ces sujets ici. L'idée pour nous est de présenter la théorie de Sapir-Whorf, car elle servira plus loin à analyser l'impact des LLM, et notamment des biais culturels et linguistiques de ces derniers, sur les équipes multiculturelles en entreprise afin de tirer des conclusions et émettre des suggestions sur le plan managérial pour une utilisation plus responsable et plus efficace des LLM en entreprise.

[10] https://thedecisionlab.com/languages/fr-ca/reference-guide/linguistics/the-whorf-hypothesis, consulté le 19/06/2025

Notre approche se range donc du côté du néo-matérialisme, qui repense les relations entre l'homme et la matière (ou le matériel) dans une approche de co-construction mutuelle plus critique, comme Jenks (2024) le résume si bien : *« This position that both humans and machines actively participate in meaning-making processes, such as interculturality, is commonly referred to as new materialism. Ontological positions, such as new materialism, have been used by scholars to reflect on how AI technologies are influencing, or are being influenced by, human cognition (e.g. Siemens et al. 2022), psychology (e.g. Crowder et al. 2020), biology (e.g. Perrakis and Sixma 2021), and even consciousness (e.g. Dong et al. 2020). » (Jenks 2024, 3)*

Il s'agira donc pour nous de voir l'impact des LLM, en contexte professionnel multilingue, dans ses différents cas d'usage, et notamment comme outils de traduction et donc de communication, et l'influence mutuelle entre les utilisateurs et les LLM. Cela passera par des questionnaires en ligne et des entretiens, dont les résultats seront analysés par la suite afin de relever les tendances principales et émettre des propositions de solutions.

3. Étude empirique : méthodologie, résultats et discussion

3.1 Approche méthodologique

3.1.1 Délimitation du champ d'étude et de la population

Notre travail porte sur l'évaluation de l'impact des LLM et des outils de traduction automatique sur la collaboration professionnelle au sein des équipes multilingues et/ou multiculturelles au quotidien. Concrètement, il s'agit d'évaluer, à partir des retours d'expériences d'utilisateurs à partir de leurs cas d'usage quotidien, dans quelle mesure les biais des LLM de type ChatGPT et les erreurs des outils de TA de type DeepL peuvent avoir un impact sur les échanges, la perception, la confiance entre des collègues de langues ou de cultures différentes, sur les performances leurs équipes, voire, à plus grande échelle, sur la réputation et les performances de l'entreprise. Après cette évaluation, il s'agira d'émettre des propositions de solutions pour réduire les biais des IA. Enfin, nous aborderons la question de la gouvernance des données et des IA, afin d'émettre également des recommandations sur ce plan pour une IA plus éthique, plus responsable et moins biaisée. Notons une fois de plus que dans le cadre de la présente étude, nous avons fait le choix de travailler uniquement avec les avis et retours d'expériences des utilisateurs. Par conséquent, nous ne nous sommes pas lancés dans des expériences pratiques avec des productions effectives de moteurs de LLM ou de TA au sein d'équipes réelles afin d'en étudier les effets dans différents contextes. La raison de ce choix est simple : le temps imparti pour le mémoire ne le permettait pas. Cela serait plus intéressant à mettre en place dans le cadre d'une étude éventuelle étude ultérieure plus poussée.

3.1.2 Collecte et analyse des données

Dans le cadre de notre étude, nous avons décidé de procéder à une collecte de données mixte jumelant questionnaires et interviews en ligne. Afin d'ouvrir l'étude à un public plus vaste et de couvrir le maximum de personnes, de cultures, d'équipes et de cas d'usage, nous avons conçu notre questionnaire en ligne en deux versions : une en français[11] et une en anglais[12]. Le questionnaire a été publié le 30 juillet 2025 et fermé le 15 septembre 2025. Le questionnaire comporte 25 questions, organisées suivant une logique de progression dans les sujets abordés en fonction de la problématique de l'étude : présentation du répondant (questions 1 & et 2) ; cas d'usage des LLM et outils de TA (questions 3 à 7) ; défis des

[11] https://forms.gle/ZSjiFJLEhqrNLcMS6
[12] https://forms.gle/LBd6gmGqoxLyCiXXA

outils de TA et LLM et focus sur la qualité des productions générées, les biais et leur impact et les mesures correctives (questions 8 à 20) ; enfin, recommandations et perspectives (questions 21 à 25). Le questionnaire a été partagé essentiellement sur LinkedIn, et a récolté 48 réponses équitablement partagées entre le français (24) et l'anglais (24).

En ce qui concerne les interviews en ligne, nous avons opté pour la plateforme de visioconférence Microsoft Teams. Ici le choix des répondants a été plus restreint, limitant les participants au contexte francophone en vue d'une transcription et d'une exploitation plus simples des résultats. Par ailleurs, en plus des deux critères d'entrée cités plus haut, la participation aux interviews visait particulièrement les profils ayant un poste de responsabilité, de management ou de direction. Nous avons donc récolté 7 participants au total. Les profils obtenus occupent les postes suivants : Product Manager, Responsable Conseil Data & IA, Tech Lead Data & IA, Responsable Data Gouvernance, Chef d'entreprise de traduction, Responsable Conformité bancaire, Directeur de start-up et Chef de projet intégrateur IT.

Pour l'exploitation et l'analyse des résultats, nous avons procédé comme suit : nous avons recueilli les réponses des questionnaires au format Google Sheets que nous avons ensuite exporté au format Excel. Quant aux interviews, nous avons enregistré et transcrit chaque échange avec l'outil intégré dans Teams. Par la suite, nous avons sauvegardé les fichiers vidéo obtenus au format MP4 et les transcriptions au format Word. La suite consistant alors à réécouter les vidéos en corrigeant les transcriptions anonymisées. Enfin, nous avons étudié les vidéos et les transcriptions finales en prenant des notes sur les parties où jaillissaient des informations saillantes en lien avec notre sujet de recherche, et en notant sous forme de citations ces parties marquantes en guise d'illustrations.

3.1.3 Hypothèses de recherche

Le postulat de départ de notre étude peut être formulé de la manière suivante : les LLM et outils de TA, lorsqu'ils sont utilisés au quotidien comme des outils de communication au sein d'équipes multiculturelles ou multilingues, peuvent générer des productions textuelles erronées du fait des biais qu'ils comportent, ce qui peut entraîner un impact négatif majeur sur les échanges, les performances, la perception et la confiance entre collègues, ainsi que des effets plus importants par exemple sur l'image, la réputation et les performances économiques de l'entreprise. Cette hypothèse initiale repose sur la théorie de Sapir-Whorf, selon laquelle la langue que l'on parle façonne notre vision d'autrui et du monde. C'est donc dire, sur la base de cette théorie, que la langue que nous font parler les LLM et outils de TA, peut engendrer une modification mentale de la manière dont nous percevons les autres et la manière dont nous échangeons avec eux, et altérer ainsi la collaboration quotidienne au travail. Le but de notre étude est donc de voir dans quelle mesure ces biais, dans leurs manifestations quotidiennes dans les LLM et les outils de TA, peuvent entacher la collaboration entre collègues dans un contexte multilingue.

Par ailleurs, nous partons également de l'hypothèse que les utilisateurs de ces outils ne maîtrisent pas nécessairement les questions de biais et les risques y afférents. Autrement dit, nous pensons que la plupart des utilisateurs des IA, quel que soit leur domaine d'activité, ont une connaissance peu poussée des possibilités pour les outils de TA et les LLM de générer des contenus orientés et fortement connotés, du fait des données sur lesquelles ils sont entraînés. Ce niveau d'acculturation faible peut donc entraîner une utilisation peu soucieuse, cause d'une grande exposition aux risques de confidentialité des données. Notre logique est donc la suivante : les utilisateurs n'ont pas forcément conscience des questions de biais ; par conséquent, ils ne sauraient pas nécessairement détecter des cas de manifestation de ces phénomènes. De ce fait, ils s'adonnent à une exploitation naïve de ces outils sans vérification des résultats en termes d'authenticité et de véracité avant réutilisation.

Enfin, notre dernière hypothèse de départ est que ces mêmes utilisateurs ne sont que peu, voire pas, acculturés aux questions de gouvernance de données et de l'IA. Cette idée, qui s'aligne dans la suite de la précédente, pose notamment, côté utilisateur final, des risques de confidentialité de données. Côté entreprise cependant, le risque est plus grand, car il y va de la qualité et du cycle de vie global des données à l'échelle du groupe. Notre postulat sur ce sujet est que, du fait de la faible acculturation des employés aux questions de gouvernance des données et des IA et de leur utilisation peu voire pas maîtrisée, les entreprises encourent de graves risques d'exposition et donc de grands dangers liés à la

qualité et à la maîtrise de leurs données et de leurs IA. Pour pallier cette situation, il convient de mettre l'accent sur l'acculturation et la formation aux questions de gouvernance des données et des IA en entreprise et de proposer un cadre méthodique en la matière, tâche à laquelle nous allons nous évertuer à la fin de notre travail.

3.2 Synthèse des résultats des questionnaires en ligne

Afin de mieux présenter les réponses de notre questionnaire, nous allons procéder dans cette section à un regroupement suivant les rubriques thématiques qui ont servi à concevoir le questionnaire. Les questions, les réponses ainsi que les graphiques assortis aux réponses seront présentés dans les annexes à la fin du présent mémoire.

3.2.1 Profil des utilisateurs et modalités d'usage

Les données révèlent une intégration systémique et différenciée des LLM et outils de TA dans l'environnement professionnel. L'adoption est massive, avec 95,8% des répondants (46 sur 48) déclarant utiliser ces outils. Cet écosystème est dominé par ChatGPT, utilisé par 75% des répondants, suivi par DeepL (47,9%) et Google Translate (41,7%). Toutefois, l'on note un risque crucial au niveau des versions utilisées : 52,1% des utilisateurs (25 sur 48) s'appuient sur des versions gratuites. Les abonnements d'entreprise ne représentent que 27,1% (13 sur 48), et les abonnements individuels 16,7% (8 sur 48). Cette prédominance du gratuit en contexte professionnel est une vulnérabilité majeure en matière de sécurité des données. En ce qui concerne les tâches les plus courantes, ces outils servent essentiellement à augmenter l'efficacité communicationnelle. L'aide à la rédaction est la tâche la plus fréquente (68,8% des répondants), suivie de la compréhension rapide de textes en langues étrangères (56,3%) et de la génération d'idées (54,2%). D'autres tâches se démarquent aussi, telles que la génération de code informatique, l'analyse de données, la réponse à des questions complexes ou encore la synthèse de réunions. La fréquence d'utilisation montre un usage intensif et contextuel. Dans le cadre des tâches liées à leur travail quotidien, 64,6% des professionnels ont un usage fréquent (« Tous les jours » à 25% ou « Plusieurs fois par semaine » à 39,6%). Quand il s'agit de faciliter la communication avec des personnes de langues et de cultures différentes, ces chiffres chutent drastiquement. Seuls 35,4% les utilisent « souvent » ou « tous les jours », tandis qu'une majorité de 64,6% les emploie « quelques fois par semaine » (27,1%), « rarement » (31,3%) ou « jamais » (6,3%).

3.2.2 Perception de la qualité et conscience des biais

L'évaluation de la performance des outils par les utilisateurs révèle une relation complexe entre satisfaction pragmatique et conscience élevée des limites. Le niveau de satisfaction global vis-à-vis des outils reste modéré : 54,2% se déclarent « plutôt satisfaits », 27,1% sont « neutres », et seulement 18,8% sont « très satisfaits ». Cette modération s'explique par la perception claire des imperfections. En effet, 62,5% des utilisateurs (30 sur 48) ont déjà constaté la présence d'erreurs dans le contenu retourné par les LLM et les outils de TA (« parfois » à 52,1% ou « souvent » à 10,4%). Les problèmes les plus courants sont : registre de langue inapproprié (43,8%), perte de nuances et simplification exagérée (41,7%), informations obsolètes (33,3%), erreurs factuelles et hallucinations (31,3%). La maîtrise des questions de biais montre un déficit notable. Près de la moitié des répondants (48%) évaluent leur connaissance des biais comme « moyenne », tandis que 25% la jugent « faible ». Seuls 20,8% estiment avoir un niveau « élevé ».

En ce qui concerne l'attention active portée à la présence d'éventuels biais dans les résultats d'un LLM ou d'un outil de TA avant exploitation, les répondants sont nettement divisés. 45,8% (22 sur 48) déclarent y prêter « toujours » attention, démontrant une posture de vigilance systématique. Cependant, un groupe presque équivalent de 43,8% (21 sur 48) ne le fait que « rarement », tandis que 10,4% (5 sur 48) n'y prêtent jamais attention. Cette statistique révèle une fracture comportementale : près de la moitié des professionnels sont des utilisateurs critiques qui intègrent le risque de biais dans leur flux de travail, tandis que l'autre moitié privilégie une utilisation plus passive et orientée vers la commodité, s'exposant davantage aux erreurs subtiles. Le point le plus saillant concerne la contribution à l'amélioration des outils. Une écrasante majorité de 81,3% des répondants ne fournit que « rarement » (43,8%) ou « jamais » (37,5%) de retours aux concepteurs ou aux administrateurs des outils pour signaler les problèmes. Seuls 18,8% (9 sur 48) le font « toujours ». Par conséquent, l'expertise des utilisateurs multilingues, qui sont les mieux placés pour identifier les biais culturels et linguistiques, est très rarement exploitée pour améliorer les modèles. Les utilisateurs corrigent les erreurs pour leur propre bénéfice (post-édition locale) mais ne participent pas à l'amélioration systémique du service. La boucle de rétroaction, essentielle à l'affinage des IA, est donc en grande partie brisée.

3.2.3 Impacts opérationnels et stratégies correctives

L'analyse de l'impact perçu des moteurs de LLM et de TA sur la collaboration professionnelle en entreprise, cœur de notre étude, révèle des résultats plutôt surprenants, mais qui trahissent un point moins aberrant, que nous appellerons l'effort de compensation humaine. Sur une échelle de 1 à 5, où 1 désignait un impact nul et 5 un impact très élevé, les utilisateurs ont apporté les jugements suivants :

- Impact faible sur la performance individuelle (moyenne 2,1/5). 47,9% des répondants le notent à 1/5 (minimal), et 25% à 2/5. Seuls 27,1% ressentent un impact modéré à fort (3/5 ou plus).
- Impact encore plus faible sur la collaboration d'équipe (moyenne 1,9/5). Une majorité de 52,1% le note à 1/5, et 27,1% à 2/5. Moins d'un répondant sur cinq (20,8%) perçoit un impact significatif.
- Impact moindre sur la prise de décision (moyenne 1,7/5). 54,2% le notent à 1/5 et 22,9% à 2/5.
- Impact minimal sur la réputation de l'entreprise (moyenne 1,6/5). Impact quasiment nul, avec 66,7% des répondants notant l'impact à 1/5.

Le faible niveau d'impact perçu s'explique par des stratégies de correction généralement révélatrices d'une charge cognitive sous-estimée, marquée essentiellement par un intense travail de correction par l'utilisateur. La correction manuelle approfondie est la stratégie majeure (utilisée par 72,9% des répondants), suivie de la recherche d'informations sur Internet pour vérification (47,9%). Le recours à un autre outil de LLM ou de TA (18,8%) ou à un expert humain (16,7%) est moins fréquent mais significatif. Les utilisateurs perçoivent donc un impact très faible des biais sur les différents aspects cités grâce à leur effort de compensation et de correction qui, par habitude, passe inaperçu.

La crainte d'uniformatisation et de perte de diversité linguistique et culturelle quant à elle affiche une opinion polarisée, marquée par une fracture nette dans la perception du risque côté utilisateurs. Sur une échelle de 1 à 5 où 1 désigne une crainte mineure et 5, une crainte très accrue de l'uniformisation linguistique signe d'une perte de diversité linguistique et culturelle au sein de l'équipe du fait de l'utilisation des LLM et outils de TA, la moyenne s'établit à 2,52/5. Cette tendance légèrement basse se répartit concrètement comme suit entre les participants : crainte faible à 52,1% (score de 1 : 25% ; score de 2 : 27,1%), crainte modérée de 25% correspondant au score de 3 ; enfin, crainte élevée de 22,9% (score de 4 : 16,7% ; score de 5 : 6,3%). C'est donc dire que l'écrasante majorité considère sans doute

ces outils comme de simples assistants dont l'influence reste maîtrisable, tandis que l'importante minorité en face (47,9%) remonte une inquiétude modérée à forte (scores de 3 à 5). Ce clivage dépend aussi d'autres facteurs tels que la profession de l'utilisateur, la version d'outil utilisée, la langue maternelle, le niveau d'acculturation aux biais, la fréquence d'utilisation des outils, etc.

3.2.4 Gouvernance des données et de l'IA

Sur le plan de l'encadrement de l'utilisation des outils d'IA en entreprise, les participants expriment une conscience généralisée des enjeux clés et nourrissent des attentes pour le moins similaires face à leurs organisations. En ce qui concerne le cadre de gouvernance actuellement en place, la situation est lacunaire et décrie un déficit global de gouvernance. Parmi les 48 répondants au total, 22,9% déclarent que leurs entreprises ont des directives claires en place en la matière. À l'opposé, 25% affirment la présence de directives floues ou mal appliquées, tandis que 27,1% critiquent l'absence de directives. 25% des participants, enfin, déclarent ne pas savoir s'il existe ou pas des directives encadrant une gouvernance des IA au sein de leur entreprise. Une analyse un peu plus détaillée sur la base de la langue de travail principale entre les personnes exerçant dans un contexte anglophone et un contexte francophone ressort quelques légères différences. Le contexte anglophone semble légèrement plus mature en matière de gouvernance avec des directives claires en place (8/24 contre 5/24 répondants). L'absence totale de directives est plus prononcée chez les utilisateurs francophones (8/24 contre 5/24). Enfin, ceux qui ne savent pas s'il existe ou non cadre formel de gouvernance des IA au sein de leur entreprise sont 2 fois plus nombreux en contexte francophone (8/24 contre 4/24). En somme, nos données montrent que près des 3/4 des entreprises (77,1%) souffrent d'un manque de gouvernance claire (directives floues, absentes ou inconnues).

L'analyse comparative suggère que les entreprises dans le contexte francophone de l'échantillon luttent davantage avec la communication de ces politiques, syndrome, peut-on supposer, d'un sujet pas encore aussi développé et maîtrisé que dans le contexte anglophone. Face à ces enjeux, les participants plébiscitent unanimement un encadrement formel. Les mesures majeures mises en avant sont : formations d'acculturation à la gouvernance (71%), besoin de directives d'utilisation claires (52%), intégration de la vérification humaine systématique (48%) et sensibilisation à la diversité linguistique et culturelle (43,75%). Les utilisateurs sont tous d'accord à l'idée que l'intervention humaine est indispensable après utilisation d'une IA générative de type LLM ou de TA, et notamment pour les documents légaux ou les contrats (93%), les supports de communication externe destinés aux clients et partenaires (77%), les rapports financiers et documents stratégiques (62,5%) ainsi que les communications internes sensibles (62,5%). Enfin, parmi les priorités stratégiques en matière de gouvernance, l'analyse complète des choix des répondants révèle une hiérarchie claire des préoccupations en matière de gouvernance des données et de l'IA. Les cinq domaines qui se détachent nettement comme étant critiques sont : la protection des données confidentielles ou sensibles (85,4%), la conformité réglementaire (79,2%), la sécurité des informations et la cybersécurité (70,8%), les questions d'éthique (60,4%) et enfin, la formation et la sensibilisation des employés à la gouvernance (54,2%).

En somme, les données récoltées au travers de nos questionnaires en ligne nous offrent des informations cruciales. À présent, nous allons approfondir davantage ces résultats à l'aide des avis et retours d'expériences concrets engrangés grâce aux interviews en ligne. Il s'agira alors, dans la section qui va suivre, d'analyser les réponses desdites interviews à la lumière des tendances tirées des données quantitatives afin de confirmer ou d'infirmer nos hypothèses de recherche.

3.3 Discussion

Les informations tirées des interviews se situent dans le prolongement des réponses aux questionnaires en ligne. Nous allons ici aborder des points saillants de notre étude en renforçant ces informations avec des articles scientifiques. Comme nous l'avons vu, notre échantillon présente un faible niveau de maîtrise des questions de biais qui entraîne une capacité aussi faible à pouvoir les détecter et les contrecarrer. Cela nous amène donc à attaquer le problème à la souche et à comprendre ici d'où peuvent provenir ces biais spécifiquement. Précisons à ce niveau que nous émettons ici une tentative d'explication sélective, qui ne saurait aucunement prétendre couvrir l'exhaustivité du sujet.

3.3.1 Causes des biais

Les biais culturels et linguistiques dans les LLM peuvent provenir de plusieurs causes diverses. Parmi elles, celles qui sont souvent revenues dans notre revue de littérature scientifique sont : la rédaction des prompts en anglais dans le cas d'études portant sur des LLM multilingues, la distribution erronée des corpus d'entraînement et l'influence des valeurs culturelles des développeurs des LLM, basés pour la plupart aux États-Unis (Y. Tao et al. 2024). Ce dernier point est confirmé par Jenks (2024) qui martèle à juste titre que les biais des LLM ne sont en réalité que la retransmission des biais humains qu'entretiennent les personnes qui conçoivent et développent ces LLM. Z. Liu (2024) corrobore cette pensée : *« However, data often exhibits incompleteness, imbalance, lack of representation, or inaccuracy, mirroring human biases in collection, processing, and labeling. »* et évoque 3 causes principales aux biais des LLM : la qualité des données, la conception des algorithmes et l'interaction des utilisateurs.

- En ce qui concerne la qualité des données, l'on note deux problèmes majeurs : l'asymétrie des données (skewed data) et les données héritées. Le premier phénomène renvoie au fait que les données utilisées dans un modèle de LLM surreprésentent une culture ou une langue en particulier, laissant ainsi très peu de place à la diversité culturelle pour un modèle plus équitable. Le second renvoie à la prise en compte, dans la constitution de corpus utilisés dans les LLM, de données obsolètes et très anciennes, qui peuvent incorporer des préjudices, stéréotypes et autres types d'informations erronées d'une certaine époque et donc les actualiser et les propager. La qualité des données a été la cause la plus mentionnée dans le cadre de notre étude par les rares répondants (3/7) qui avaient une connaissance du sujet.
- Les biais algorithmiques, quant à eux, peuvent provenir de deux sources majeures : le choix des mesures et le manque de transparence. Dans le premier cas, il s'agit de bien choisir les mesures appropriées et pertinentes pour évaluer le niveau de performance et d'équité des algorithmes des IA et LLM. Autrement dit, des mesures (metrics) mal sélectionnées peuvent entraîner des erreurs dans les algorithmes et entraîner des études déséquilibrées, faussées et mal ciblées. (Z. Liu 2024) Le manque de transparence renvoie au phénomène dit de la boîte noire (black box) mentionné plus haut, selon lequel les utilisateurs des IA et LLM n'ont pas accès au contenu exact des composants de ces outils qu'ils utilisent, d'une part. D'autre part, l'opacité des LLM trahit l'incompréhension et la complexité-même de ces systèmes aux milliards de paramètres. Cette complexité intrinsèque entraîne donc un manque de transparence des humains face aux LLM, et affecte par conséquence le rapport de confiance entre ces deux, rapport pourtant primordial pour une bonne utilisation et une bonne collaboration homme-machine.
- Enfin, les utilisateurs eux-mêmes peuvent être à l'origine des biais dans les LLM à travers deux facteurs majeurs : les boucles de commentaire (feedback loops) et la mauvaise utilisation des LLM. Dans le premier cas, les utilisateurs nourrissent et enrichissent les LLM à travers leurs avis et commentaires, au fur et à mesure qu'ils les utilisent. Cependant, bien que cette pratique vise à l'origine à améliorer les LLM, elle contribue de manière subtile à renforcer et maintenir les biais dans la mesure où les utilisateurs auront tendance à laisser des avis et commentaires positifs sur les résultats qui corroborent leurs propres biais culturels, leurs pensées et leurs idées. Le second phénomène relève d'une ambition purement malsaine des utilisateurs : *« Misuse of AI involves intentionally exploiting AI systems for malicious purposes, such as spreading harmful stereotypes, propaganda, or misinformation. This can occur through feeding biased data to the AI, manipulating its training process, or exploiting vulnerabilities,*

reinforcing biases and undermining the trustworthiness and fairness of the AI. » (Z. Lui 2024, 7) L'on retrouve ceci dans tous les cas de cyberattaques par exemple, sous toutes ses différentes formes. De même, les discours racistes et autres formes de propagandes de discrimination que l'on peut relayer au travers de médias, et donc de données qui peuvent servir à alimenter des LLM. Parmi ces malversations d'usage des IA, l'on peut citer le cas des injections d'invites (Prompt Injection) qui nous a été soulevé par l'un des participants (MM) parmi les risques liés aux biais des IA. Cette technique consiste, par le biais d'un prompt ou d'une invite de commande, à pousser un modèle de langage (LLM) à générer du contenu indésirable, trompeur voire dangereux.

3.3.2 Manifestations et impact

Les personnes ayant participé aux interviews affirment en grande majorité (5/7) une utilisation encouragée des IA génératives dans leur travail, au sein de leur équipe ou de leur entreprise. Les avantages qu'ils en tirent sont nombreux : gain de temps, optimisation de la productivité, amélioration des processus, automatisation des tâches répétitives, précision dans la rédaction, analyse rapide de données, rapport coût-efficacité, etc. Malgré ces points positifs, ces outils présentent tout de même des défauts dont la manifestation la plus récurrente est, selon les retours des participants, l'hallucination. Ce phénomène renvoie au fait pour les LLM, de *« générer du contenu hors contexte »,* comme le définit l'un des participants (MM). De manière résumée, on peut décrire les hallucinations comme des résultats trompeurs, incorrects voire totalement ou partiellement inventées par les modèles d'IA, sans aucune trace de véracité. Pour des raisons de simplification terminologique dans le cadre de notre travail, nous allons étendre le concept d'hallucination aux modèles de TA, pour englober de leur côté, les cas où le moteur de TA renvoie une traduction partiellement ou entièrement erronée ou inventée, sans lien avec le texte source. Parmi les autres biais cités de façon sporadique (1/7), l'on a la préférence à coller des genres d'emblée à certains métiers, révélant ainsi une tendance sexiste des IA.

Quelle que soit la forme sous laquelle ils se manifestent, les biais des IA engendrent des conséquences. Ces dernières peuvent avoir un impact relativement grave ou moins grave, en fonction de la situation et des enjeux sociaux, sociétaux, économiques, politiques, environnementaux, etc. du cas. Dans le cas de notre étude, nous avons questionné les participants sur les conséquences sur le plan humain et économique à l'échelle de leur secteur et champ d'activité. Malgré la difficulté à répondre à cette question (comme à plusieurs autres) pour des raisons de confidentialité, nous avons quand même pu recueillir quelques témoignages, anonymes et superficiels. Deux cas (FP et DPT) font état d'une situation d'insatisfaction client du fait d'un contenu généré ou traduit par IA et livré quasiment voire totalement sans correction. Un autre (SN), dans un environnement de start-up, révèle un cas où un usage abusif d'une IA et sans correction par un membre de son équipe sur un document technique clé pour le client a créé une situation de tension après que la supercherie a été découverte par le client à la réception dudit document. À plus grande échelle, un répondant (MM) présente les risques de l'utilisation mal contrôlée de l'IA dans le contexte d'une multinationale d'assurance, où les conséquences peuvent avoir des effets sur le groupe entier, sur sa collaboration avec ses partenaires internationaux et sur les clients. Dans la même veine, un dernier participant (DPT), au sein d'une entreprise internationale de commerce en ligne, décrit une situation similaire, attirant l'attention sur le fait que les conséquences peuvent même toucher à l'image de marque du groupe et baisser son chiffre d'affaires.

Nous voyons donc que les IA génératives, et dans ces cas, les LLM, peuvent comporter de nombreux biais qui eux, peuvent se manifester de diverses manières. Cependant, nous savons aussi que les biais des IA ne sont que le reflet des biais humains qui ont été glissés soit dans les données d'entraînement soit dans les algorithmes de ces modèles. L'on se retrouve donc dans le cas de co-construction néo-matérialiste (Jenks, 2024) selon laquelle l'IA et l'humain exercent simultanément une influence réciproque. Les modèles sont conçus avec des données contenant des erreurs, des stéréotypes, des mensonges ou des faits truqués, et les ressortent à leur tour face aux requêtes des utilisateurs humains. Or, ces derniers, lors de l'exploitation ou de la réutilisation des résultats générés par les IA, vont étendre la chaîne de circulation de ces biais en les véhiculant, avec ou sans correction. C'est cette capacité qu'ont les IA à nous faire parler la langue de leurs résultats qui peut être perçue ici, selon notre entendement,

comme une application de la théorie dite de relativité linguistique de Sapir-Whorf. Comme pour la TA, la langue générée n'est pas vraiment une langue naturelle dans la mesure où elle n'est pas générée par un cerveau humain. Il s'agit en réalité d'une sorte d'interlangue, entre celle de l'utilisateur devant son écran, et les règles algorithmiques et statistiques des modèles d'IA, qui ne font en réalité que prédire et proposer une suite de mots, les uns après les autres sur la base de son corpus d'entraînement. Or, l'utilisation de ces outils au quotidien aussi bien sur le plan professionnel que personnel, finit par en faire de véritables partenaires, des aides à la réflexion et parfois même des confidents, dont la relation peut s'avérer fatale[13].

Malheureusement, la taille de notre échantillon et les données recueillies ne nous permettent pas de confirmer avec plus de conviction cette influence mutuelle entre l'homme et l'IA et surtout, l'effet sur les relations humaines notamment en milieu professionnel. L'un des effets que l'on peut citer ici et qui a été mentionné de façon sporadique est la tendance à l'uniformisation de la langue du fait de l'utilisation des LLM pour la rédaction. Ce point mentionné par un participant (FP), fait état, pour des utilisateurs au sein de son équipe, dont le français n'est pas la langue première, d'adopter un style écrit qui laisse entrevoir des traces d'influence de la langue anglaise dans leurs écrits en français, notamment à travers les tournures syntaxiques et grammaticales. Si notre étude ne nous permet pas de confirmer avec certitude l'influence des LLM sur la vision du monde des utilisateurs et sur les relations humaines en milieu professionnel, c'est aussi du fait même du faible niveau d'acculturation et de connaissance des utilisateurs en ce qui concerne les questions de biais. Ce constat pose donc le problème de l'urgence d'une acculturation aux questions de biais des IA et de leurs possibles conséquences. Certains utilisateurs, bien que rares, qui ont conscience de ces problématiques, affirment avoir recours à des solutions techniques personnelles ou d'entreprise, pour corriger, contourner ou améliorer ces biais.

3.3.3 Solutions

En plus de la relecture et de la correction manuelles largement plébiscitées, quelques solutions techniques ont été mentionnées pour réduire les biais et les hallucinations dans les IA génératives. Parmi ces solutions mises en place dans les entreprises où exercent nos participants, l'on a :

- La dynamisation des modèles de LLM grâce au RAG (Retrieval Augmented Generation) pour une meilleure contextualisation. La génération à enrichissement contextuel consiste à alimenter un modèle de langage avec une base de documents fiables internes à l'entreprise, afin d'optimiser ses résultats. Concrètement, il s'agit par exemple de rajouter à un chatbot basé sur ChatGPT, un ensemble de documents internes à une banque (contrats, fiches de postes, fiches produits, guides pratiques, documents administratifs et juridiques, etc.) afin de permettre à l'outil de générer des résultats et des réponses plus contextualisées, plus précises, plus vraies, plus factuelles et plus récentes. Cette technique permet notamment d'entraîner les modèles dans un contexte plus précis afin d'éviter les hallucinations, les réponses obsolètes ou encore des réponses issues de sources peu voire pas fiables.
- La mise en place d'un système de « LLM as a judge », que l'on peut traduire par LLM-juge en français. Cette technologie a été mentionnée par deux participants (FP et MM) qui ont très vite martelé la difficulté d'implémentation de cette technologie du fait qu'elle soit assez onéreuse, notamment pour les petites et moyennes entreprises. Mais, pour les grandes entreprises qui peuvent se permettre ce luxe, cette technique peut s'avérer efficace contre les biais et leurs manifestations dans les résultats générés. Concrètement, il s'agit de mettre sur pied un LLM dont le rôle ne consiste pas à générer du contenu, mais à évaluer la qualité des résultats générés par d'autres LLM sur plusieurs aspects : véracité, clarté, exactitude, pertinence, récence, neutralité, etc. Cette solution permettrait d'avoir une IA plus fiable et moins biaisée, avec des résultats plus neutres.
- La mise en place d'agents IA, avec en bout de file, une IA chargée de la validation du travail des autres IA. Cette solution n'est pas sans rappeler la précédente, à la seule exception qu'ici, le modèle qui valide est intégré dans une chaîne de modèles autonomes dont il juge le travail en toute fin de

[13] En 2024, un adolescent se donne la mort aux USA après des échanges avec un chatbot : https://www.nytimes.com/2024/10/23/technology/characterai-lawsuit-teen-suicide.html

processus avant la génération du résultat final. Cette solution permettrait, aussi bien pour les LLM que pour les outils de TA, de mieux orchestrer la génération de contenus et surtout, de mieux maîtriser le résultat retourné à l'utilisateur en termes de qualité selon des critères bien définis.

- La dernière solution, à la fois technique et managériale, consiste à réentraîner les modèles (LLM et TA) avec les versions corrigées des résultats qu'ils génèrent et d'itérer sans cesse sur la durée jusqu'à ce que ces modèles s'améliorent. En parallèle, il faut mettre en place des boucles de retours et d'avis (feedback loops) pour permettre aux utilisateurs d'émettre des avis et commentaires détaillés et illustrés dans l'outil et aux administrateurs de l'outil afin d'améliorer la qualité des résultats. Enfin, il faut mettre en place des systèmes et métriques permettant de suivre l'évolution de la performance des modèles sur le temps afin d'éviter une dérive (drift) de ces modèles. L'on entend par dérive la dégradation progressive des performances d'un modèle sur le temps, qui se traduit dans les résultats qu'il génère.

Côté recherche, Y. Tao et al. (2024) proposent le « Cultural prompting » comme solution pour réduire les biais, notamment la tendance des LLM à baser par défaut leurs résultats sur des contenus américains. Le cultural prompting, que l'on peut traduire par prompting culturel, requêtage culturel ou encore interrogation culturalisée, consiste à rajouter des aspects culturels précis dans la requête lorsque l'on interroge un LLM, afin d'affiner ses résultats et d'obtenir des réponses qui ressortent précisément les traits d'une culture donnée, sans que celle-ci ne soit dominée ou écrasée par défaut par une autre culture (l'anglais par exemple) incorporée aux données et aux algorithmes de l'outil. Cela revient par exemple à poser une question à un LLM et de lui demander de répondre comme une personne d'un statut social donné, d'un âge donné et issue d'un pays ou d'une communauté précise et/ou résidant dans une ville, un pays ou autre localité bien précise. L'interrogation culturalisée permet donc de réduire ces biais culturels et d'améliorer l'alignement culturel des LLM.

De même, Z. Liu (2024), propose quelques recommandations éthiques pour atténuer la présence de biais culturels et linguistiques dans les IA et LLM, telles que :

- La nécessité pour les développeurs de rendre publiques les sources de données, les méthodologies d'entraînement, les biais rencontrés et l'utilisation de mesures d'évaluation de données pertinentes et équitables
- L'implication proactive des utilisateurs dans la conception des LLM et la formation de ceux-ci aux avantages et inconvénients des LLM
- La transmission par les développeurs d'informations transparentes et compréhensibles quant au fonctionnement des LLM, leur fiabilité et leur utilisation responsable ainsi que la conception d'interfaces empêchant des utilisations abusives
- L'étude préalable des utilisateurs pour comprendre les besoins et attentes de différents groupes et notamment des groupes sous-représentés, afin de concevoir des LLM plus inclusifs
- La mise en place de mécanismes d'avis et commentaires et de rapports, afin que les utilisateurs partagent leurs opinions sur les LLM et remontent les éventuels problèmes ou difficultés
- La formation et l'acculturation des utilisateurs aux enjeux éthiques et sociaux des LLM
- La transparence, côté développeurs, quant à l'origine des données, leurs biais et les modèles utilisés
- L'utilisation de données variées et représentatives couvrant des cultures, contextes, langues et populations variées pour des LLM plus variés et inclusifs et moins déséquilibrés
- La réalisation de tests complets pour une meilleure validation des LLM sur divers contextes culturels

Bien que notre échantillon soit limité et que les observations ne puissent être généralisées à l'ensemble des utilisateurs de LLM et de TA, nous voyons tout de même qu'il s'en dégage de belles pistes de solutions en vue de la réduction des biais dans ces outils, dans leurs différentes formes de manifestation. Cependant, ces solutions ne résolvent pas entièrement les problèmes posés d'entrée de jeu dans notre sujet et nous pouvons constater au travers de nos questionnaires et entretiens qu'un autre aspect reste trivial, à savoir celui de la gouvernance des données et de l'IA. Face au faible niveau d'acculturation, de connaissance et de mise en œuvre de nos participants en ce qui concerne ce sujet,

nous nous proposons dans la dernière partie qui suit, d'aborder cette problématique et de suggérer un cadre méthodique d'application pour un meilleur encadrement des données et des IA.

4. La gouvernance des données et de l'IA comme réponse aux biais

Jenks (2024) rappelle que les biais des LLM ne sont rien d'autre que le reflet des biais humains transférés dans les données et les algorithmes des modèles lors de leur conception. Cette assertion devrait permettre de recadrer le débat en matière de lutte contre les biais des IA et de leurs effets. Autrement dit, il convient de prêter plus d'attention aux données sur lesquelles sont entraînées les modèles d'IA. Cette préoccupation se veut encore plus cruciale de nos jours, quand on sait que le volume de données sur Internet croît à une vitesse éclair, avec un nombre situé autour de 180 zettaoctets en 2025. Cette euphorie pour le Big Data s'accompagne, depuis l'avènement des IA génératives, d'une recrudescence de projets IA. Pourtant, le MIT estime à 95% le taux de projets pilotes IA portés par des entreprises qui échouent ou du moins, n'arrivent pas jusqu'à la phase de mise en production[14]. Ce taux vient peut-être trahir une volonté trop hâtive de se lancer directement dans le développement de modèles sans réelle définition profonde des cas d'usage, des besoins véritables des métiers et des utilisateurs, et surtout, une gestion quelque peu superficielle ou pas suffisamment encadrée des données, moteurs des modèles d'IA. Dès lors, il se pose donc des défis majeurs liés à la réglementation, à la qualité des données et aux complexités organisationnelles en vue d'une IA plus fiable, plus performante et plus éthique. La réponse à ces défis se trouve, à notre sens, dans une gouvernance maîtrisée des données et de l'IA. Mais que cache concrètement ce concept ?

4.1 Définition de la gouvernance

Cadre méthodologique de référence en matière de gestion et gouvernance des données, le DAMA-DMBOK (2017)[15]définit la gouvernance des données (GD) comme *« the exercise of authority and control (planning, implementation, monitoring, and enforcement) over the management of data assets. »* Elle est la fonction centrale qui guide et contrôle toutes les autres, en matière de management des données. Cette dernière se définit selon le même référentiel comme le processus consistant à gérer les données pour maximiser leur valeur tout au long de leur cycle de vie. Son but est de s'assurer que les organisations tirent pleinement valeur de leurs données. Cela passe par une bonne gouvernance, qui fournit les principes, la politique, les processus, le cadre, les métriques et la surveillance nécessaire pour orienter les activités liées à la gestion des données. L' objectif de la GD est de permettre aux organisations de gérer leurs données comme des actifs stratégiques, au même titre que les actifs mobiliers, financiers, etc. Par conséquent, la GD est au cœur des autres activités de management des données, avec qui elle entretient des relations d'interdépendance, comme le montre la fameuse roue du framework DAMA.

[14] https://www.forbes.com/sites/andreahill/2025/08/21/why-95-of-ai-pilots-fail-and-what-business-leaders-should-do-instead/ il convient cependant de prendre ces chiffres avec des pincettes, quand on sait que cette étude se base sur un échantillon restreint de 300 projets publics, 52 interviews et 153 questionnaires remplis

[15] Data Management Body Of Knowledge 2e édition de 2017, guide méthodologique conçu par DAMA International en vue du passage de certifications en Management des données

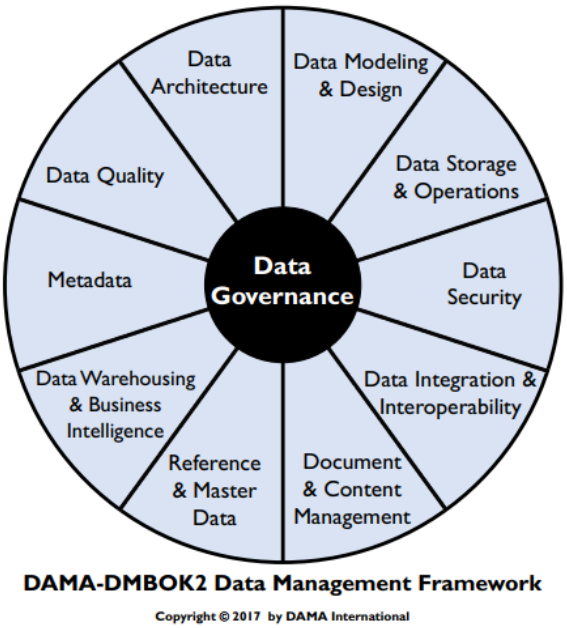

Fig. 2 : DAMA Wheel

La gouvernance de l'IA (GIA) quant à elle, est définie par Collibra (2024), éditeur de logiciel phare en matière de gouvernance Data et IA, comme *« the application of rules, processes, and responsibilities to drive maximum value from your automated data products by ensuring applicable, streamlined, and ethical AI practices that mitigate risk, adhere to legal requirements, and protect privacy ».* C'est donc dire que si la GD assure la qualité des données en tant que carburant, la GIA assure la fiabilité, la conformité et la sécurité du moteur qui consomme ce carburant. Son implémentation permet d'améliorer la traçabilité, de réduire les risques et d'optimiser le développement des modèles d'IA à travers une collaboration interfonctionnelle. Consciente de ces enjeux, l'UE a formalisé un cadre réglementaire dédié à l'IA à travers l'AI Act entré en vigueur en 2024. Dans une approche basée sur le risque, ce cadre classe les IA selon quatre niveaux :

- Les IA à risque inacceptable, qui sont strictement prohibés car elles menacent les droits fondamentaux
- Les IA à haut risque qui sont soumises aux exigences les plus strictes en matière de qualité des données, de documentation et de supervision humaine
- Les IA à risque limité qui nécessitent des exigences de transparence spécifiques, et enfin
- Les IA à risque minimal ou nul, qui décrivent la majorité des systèmes pour lesquels des codes de conduite volontaires sont encouragés

Informatica (2024), autre éditeur de logiciel clé en matière de GD et GIA dans l'Hexagone, insiste sur le fait que l'efficacité d'une IA est subordonnée à la qualité des données : comme on le dit en anglais, *« garbage in, garbage out ».* Des données d'une qualité médiocre peuvent donner lieu à des résultats erronés, des décisions biaisées, des hallucinations, des recommandations inexactes ou encore des risques de sécurité. La GIA vient donc optimiser la qualité et la fiabilité des données, éliminer l'opacité derrière les algorithmes d'IA et assurer la transparence nécessaire sur les modèles, dans une approche humano-centrée.

4.2 L'humain au cœur du changement

L'implémentation de la GD/GIA exige en amont une transformation en matière de culture d'entreprise et de comportement, du niveau individuel jusqu'à l'échelle du groupe. Toutefois, le changement est souvent accueilli avec beaucoup de réticence et la résistance au changement peut provenir de différents acteurs à tous les niveaux de l'entreprise. Cette résistance peut prendre plusieurs formes : refus d'adopter de nouvelles technologies, refus de participer à des projets d'IA ou encore simplement un manque d'enthousiasme général face au changement (Collibra, 2024). C'est pourquoi il est essentiel de faire preuve de leadership dans la conduite du changement et de mettre en place une méthodologie adaptée. Parmi les modèles populaires en conduite du changement, l'on peut citer le modèle en 8 étapes de Kotter, le modèle ADKAR de Jeff Hiatt ou encore le modèle PDCA de Deming.

Le modèle ADKAR structure le changement individuel autour de 5 étapes essentielles :

- Awareness (prise de conscience) : ici, l'individu prend conscience du besoin et de la nécessité du changement
- Desire (désir) : ici, l'individu s'engage volontairement à porter l'effort de changement
- Knowledge (connaissance) : ici, l'individu engrange le savoir sur la manière de procéder au changement. Cela peut passer par de la documentation, un accompagnement ou des formations
- Ability (capacité) : ici, l'individu se montre capable d'appliquer concrètement les nouvelles compétences et comportements acquis
- Reinforcement (renforcement) : ici, l'individu suit des mesures et indications afin de s'assurer de l'intégration et du maintien du changement

John P. Kotter propose une méthode en 8 étapes pour les changements de plus grande envergure, telle que la mise en place d'une GD ou GIA au sein d'une organisation :

- Établir un sentiment d'urgence : quitter le statu quo et la complaisance de la zone de confort, éliminer les résistances et obtenir l'acceptation unanime pour le changement
- Former une coalition : s'entourer des personnes ayant suffisamment de pouvoir, de crédibilité, de leadership et d'expertise pour guider l'effort de changement
- Développer une vision et une stratégie : projeter avec la coalition une image à court, moyen et long terme de l'organisation dans l'état que l'on souhaite atteindre, et mettre en place les moyens et la manière d'y parvenir
- Communiquer la vision du changement : ici, le manager fait preuve de charisme et de leadership pour insuffler la dynamique du changement sur le plan opérationnel à travers des outils de communication pertinents
- Responsabiliser les collaborateurs : inciter l'équipe à l'action en donnant à chacun des tâches et des responsabilités
- Générer des résultats à court terme : fixer des objectifs intermédiaires et célébrer avec l'équipe les petits succès concrets et mesurables afin de maintenir la motivation du groupe
- Consolider le succès pour plus de changement : utiliser la crédibilité gagnée par les premiers succès pour aborder des changements systémiques plus profonds
- Ancrer les nouvelles approches dans la culture d'entreprise : une fois le changement opéré, il s'agit ici en phase finale, d'intégrer l'état final désormais réalisé dans la culture de l'organisation

Enfin, le modèle PCDA de W. Edwards Deming, sert à la fois au changement, à l'amélioration continue et à la gestion de la qualité. Elle peut permettre d'instaurer une GD/GIA ou, le cas échéant, d'améliorer celle déjà en place. Pour ce faire, il faut :

- Planifier (Plan) : définir clairement le problème et concevoir un plan d'action
- Exécuter (Do) : mettre en œuvre le plan à petite échelle

- Vérifier (Check) : mesurer les résultats obtenus
- Agir (Act) : ajuster le processus et le déployer

La liste des méthodes n'est pas exhaustive. Quelle que soit celle que l'on choisit, il faut garder à l'esprit en permanence que l'humain doit rester au centre de la démarche. C'est pourquoi il convient à juste titre aussi, de constituer une équipe de GD/GIA et d'attribuer des rôles spécifiques aux membres.

4.3 Rôles, responsabilités et technologies

En GD/GIA tout comme en politique, il est question de gouverner. Cela implique aussi bien des fonctions législatives (définition des politiques, normes et architecture) que des fonctions juridiques (gestion des conflits et arbitrage) et exécutives (protection, service et responsabilités administratives) (DAMA-DMBOK 2017, 79). Ces fonctions nécessitent donc de désigner des personnes et de leur attribuer des rôles et des responsabilités bien définis. Comme pour tout projet, il convient s'établir une architecture claire des rôles à l'aide d'une méthode bien définie. La matrice RACI peut s'avérer utile à ce niveau afin de bien définir les rôles des différentes parties prenantes. Il s'agit d'étudier chacune des personnes impliquées, et de définir à travers sa position au sein de l'entreprise, son intérêt pour le projet et son implication dans le projet, afin de lui attribuer l'un des rôles suivants :

- Responsable : personne chargée de l'exécution du travail
- Approbateur : dirigeant ayant l'autorité finale sur toutes les décisions critiques du projet
- Consulté : expert métier et/ou technique qui fournit de précieuses connaissances et informations au projet
- Informé : intervenant impacté ou intéressé par le projet et qui mérite d'être tenu informé des progrès et des changements, sans aucun pouvoir de décision sur le projet

La définition de ces rôles doit s'accompagner ensuite de la mise en place d'une équipe formelle avec des rôles précis afin de garantir la pérennité, la traçabilité et une autorité ferme sur l'ensemble des fonctions liées au management des données. Dans une équipe de GD/GIA, l'on doit retrouver :

- Un Chief Data/AI Officer (CDO) qui est responsable de la stratégie de gouvernance GD/GIA globale de l'entreprise en collaboration avec la direction et les managers
- Un ou des Data Stewards : experts métier qui ont la responsabilité des données et assurent la mise en œuvre opérationnelle de la stratégie définie par le CDO au niveau des équipes métier
- Un ou des Data Owners qui sont responsables des décisions liées aux données au sein de leur département. Généralement, ce rôle est attribué aux responsables de services (marketing, RH, finance, juridique, opérations, etc.) pour plus de facilité, d'engagement et de fiabilité
- L'on peut également avoir des experts en conformité juridique, risque et sécurité pour s'assurer de la conformité des données et des modèles et s'assurer que la GIA respecte les exigences réglementaires de sécurité
- Enfin, les rôles techniques tels que les Data/AI architects (pour coordonner la stratégie de gouvernance avec la conception technique), les Data/AI engineer (pour appliquer les normes de gouvernance dans la collecte, le prétraitement des données en vue de leur exploitation et la création des pipelines) et enfin les Data analysts et Data scientists (pour l'exploitation opérationnelle des données en vue des analyses à but décisionnel et la conception des modèles de ML et DL en accord avec la stratégie de gouvernance)

En matière de technologies, les systèmes de GD/GIA modernes nécessitent une plateforme évolutive et intelligente. Des éditeurs de logiciels tels que Collibra et Informatica proposent aujourd'hui des

solutions complètes et éprouvées pour une GD/GIA bien orchestrée. Elles sont de plus en plus boostées à l'IA pour plus d'automatisation et de scalabilité. Quel que soit le choix technologique, il convient de mettre en place des outils pour une bonne gestion opérationnelle de la gouvernance au quotidien. Cela passe par exemple par :

- Un catalogue de données : pour la définition fonctionnelle des données disponibles
- Des outils de qualité et d'observabilité des données : pour avoir un œil en permanence sur l'état des données
- Des outils de traçage des données (Data lineage) : pour la traçabilité des données, de leur origine à leur utilisation finale en passant par les éventuelles modifications de données, métadonnées, stockage, propriété, etc. à des fins de reporting et de conformité réglementaire
- Un répertoire de métadonnées pour mieux gérer, catégoriser et sécuriser les informations sur les données afin de protéger automatiquement les nouvelles données dès leur transfert et de faciliter la recherche
- Un glossaire métier pour consolider la terminologie partagée en lien avec les métiers et les données
- Des outils de communication centralisés pour partager plus facilement la vision et la stratégie de gouvernance, la documentation nécessaire et disponible, faciliter la recherche documentaire et simplifier les flux de processus
- Une console de gouvernance centralisée pour automatiser le reporting et le suivi des métriques des activités de GD/GIA afin de garantir l'alignement avec la vision, l'alignement stratégique et la conformité

La GD/GIA est donc une activité principalement centrée sur l'humain et qui nécessite cependant des outils et technologies pour une application réussie. Sachant que la gouvernance se résume à un rapport triangulaire entre personnes, processus et outils, nous allons à présent voire comment implémenter des processus de GD/GIA.

4.4 Proposition de mise en œuvre

Nous suggérons d'adopter une méthode expérimentale basée sur l'empirisme et l'amélioration continue. Cela passe par une implémentation itérative axée sur la démonstration rapide de la valeur pour l'entreprise. La valeur des données proviennent directement des cas d'usage. Les données en elles-mêmes n'ont pas de valeur estimable aussi bien sur le plan économique, financier que stratégique ou opérationnel/métier. Cela vaut aussi pour l'IA. Par conséquent, c'est ce qu'on en fait concrètement en entreprise qui peut générer de la valeur, observable et mesurable. C'est pourquoi il convient d'adopter une approche itérative afin de percevoir les retombées progressivement et d'ajuster le processus au fil de son évolution. Notre proposition en 5 phases se fonde sur les recommandations du DAMA-DMBOK et du guide de GIA d'Informatica.

- Phase 1 : initiation du projet et alignement stratégique. Il est crucial de démarrer modestement en ciblant un petit projet lié à un cas d'usage bien précis ou à un métier particulier en l'alignant sur les données stratégiques de l'entreprise. Pour ce faire, il est important d'obtenir le soutien de sponsors (dirigeants) au sein de l'entreprise, qui ont un intérêt personnel considérable à la réussite de l'initiative. Cela passe par une écoute active de leurs besoins, la valorisation de leurs priorités et une communication claire de la vision. Il est donc nécessaire, avant de se lancer, d'évaluer le niveau d'aptitude de l'entreprise à travers l'analyse du niveau de maturité en matière de gestion des données, d'ouverture au changement et à la collaboration et enfin d'alignement stratégique. Tout cela permet ensuite de cibler un cas d'usage pilote.

- Phase 2 : encadrement et définition de la stratégie. Les objectifs de l'initiative doivent être clairs et reliés à des indicateurs quantifiables. Ils doivent répondre à la méthode SMART (spécifiques, mesurables, atteignables, réalistes et temporellement définis). Ces objectifs doivent être consignés dans la stratégie de gouvernance qui, elle, doit être alignée sur la stratégie d'entreprise, et comprendre une charte (pour la vision et l'état des lieux), un cadre opérationnel avec des rôles bien définis (pour les responsabilités liées aux activités), une feuille de route (pour les jalons majeurs de mise en œuvre), un plan opérationnel (pour décrire l'état cible visé et les activités en vue de sa pérennisation), la valeur des données pour l'organisation et enfin, le modèle opérationnel. C'est ici qu'est créée la matrice RACI et le glossaire métier.
- Phase 3 : exécution et développement. Tout commence par la découverte (discovery) et le profilage des données afin de comprendre leur état, leur importance au sein de l'entreprise, les processus métier qui les impactent et leur utilisation dans les modèles d'IA. Ensuite, il faut documenter ces données en leur attribuant des définitions, des politiques, normes et processus. Il est crucial ici de désigner les propriétaires des données (data owners), d'appliquer les politiques de gouvernance et les règles métier, et de définir les métriques clés et KPI. La data lineage est également mise en œuvre ici, en collaboration avec les architectes. Enfin, il est essentiel de constituer des équipes interfonctionnelles pour une meilleure intégration des divers perspectives et compétences. Les managers, dans une posture de facilitateurs et d'exemples, encouragent une communication régulière à travers une stratégie de données unifiée.
- Phase 4 : mesure et contrôle. Ici, l'on mesure la valeur des efforts en matière et de gouvernance ainsi que leur conformité avec les politiques internes et externes en vigueur. Cela nécessite toutefois d'identifier et d'acquérir toutes les données requises de manière centralisée afin d'éviter les erreurs dues à la dissémination des données. Les résultats de GD/GIA doivent être surveillés en permanence pour mieux les intégrer dans le quotidien. L'équipe, portée par les managers, doit s'engager comme un seul homme à la résolution de toute anomalie détectée ainsi que dans la résolution des risques et des conflits. Le processus de contrôle passe aussi bien par des audits réguliers que par la mise en place de KPI et métriques qualitatives et quantitatives de performance. Mais au-delà de ces éléments, il est également important de promouvoir la culture du retour d'expérience et d'avis (feedback) de toutes les parties prenantes afin d'améliorer à la fois les activités et les processus et reprioriser continuellement les objectifs. Toutes ces informations doivent être consignées dans des journaux partagés et tenus à jour pour une meilleure traçabilité des opérations.
- Phase 5 : pérennisation. Il s'agit ici d'assurer la durabilité de l'initiative de gouvernance en misant sur la culture d'entreprise et le maintien voire l'amélioration de la valeur à travers la formation. L'AI Act exige un niveau d'acculturation suffisant du personnel aux questions d'IA dans les entreprises. Cela couvre la compréhension et l'application des éléments techniques et l'interprétation des résultats. Cela permet notamment de démystifier les IA et leurs algorithmes opaques et incompréhensibles, ce qui facilite la compréhension des modes de raisonnement et des enjeux de sécurité. Les organisations doivent fournir des formations facilement accessibles, allant des guides pratiques aux cours à la demande, parcours d'apprentissage et certifications pour un développement complet des compétences.

5. Conclusion

Ce mémoire a interrogé l'impact des biais linguistiques et culturels des IA génératives (LLM et outils de TA) en contexte professionnel multiculturel, à la lumière de la théorie de Sapir-Whorf. La problématique était double : comprendre comment la relativité linguistique et les dynamiques culturelles se manifestent dans les sorties des LLM et influencent la collaboration d'équipe, puis déterminer quel

cadre de gouvernance des données et de l'IA permet d'en limiter les risques sans en brider la valeur d'usage.

La démarche empirique a combiné un questionnaire quantitatif et des entretiens semi-directifs. Les réponses, majoritairement issues d'un contexte francophone, confirment des frictions récurrentes. Malgré les nombreux avantages cités, l'utilisation professionnelle des LLM fait l'objet d'une importante méfiance quant à ses résultats. Il nous est toutefois difficile de confirmer ou d'infirmer concrètement l'effet des biais sur la collaboration professionnelle à partir de nos données. Quoi qu'il en soit, ce travail a éveillé une prise de conscience non négligeable sur le faible niveau d'acculturation des utilisateurs des outils d'IA, professionnels ou particuliers, sur les risques de ces outils, leurs biais et leurs possibles conséquences, ainsi que, plus important encore, sur les questions de gouvernance des données et de l'IA.

Ces constats nous ont permis d'émettre des propositions d'ordre managérial et opérationnel. Plus précisément, nous avons préconisé la nécessité, pour les entreprises, de former et d'acculturer leur personnel aux différents enjeux liés aux IA, notamment aux LLM. Cela leur permettra de respecter l'exigence de l'AI Act qui demande de la part des employés d'entreprise et d'utilisateurs des IA, d'avoir un niveau d'acculturation suffisant. Cela passe, selon notre observation, par un plan de gouvernance bien ficelé, porté par des sponsors exécutifs, qui pour une application plus légitime, doivent être des dirigeants, managers et autres hauts cadres de l'entreprise. Notre étude demeure toutefois limitée par son échantillon restreint, francophone et auto-déclaratif, l'absence d'expérimentations contrôlées et de suivis longitudinaux, un temps d'enquête contraint, et l'absence de tailles d'effet et de benchmarks systématiques ; la faible acculturation de certains répondants peut aussi biaiser certaines perceptions.

Sur le plan académique, notre travail contribue à opérationnaliser la théorie de Sapir-Whorf en milieu professionnel. Son originalité tient au croisement entre linguistique et gouvernance Data/IA, et à la traduction d'attentes d'utilisateurs en exigences actionnables pour l'entreprise, créatrices de valeur et réductrices de risque. L'homme et l'IA exercent une influence mutuelle dans une relation de co-construction, et il est plus qu'important d'éduquer à la fois les utilisateurs humains et les modèles, afin de réduire le risque d'exacerbation de cette double influence et les conséquences dans la société. Ici aussi, cela passe par une gouvernance bien maîtrisée des données et de l'IA, dont nous avons suggéré un plan d'implémentation. La formation et l'acculturation à la gouvernance des données ne concernent pas que les entreprises ; elles doivent être instiguées dès le milieu académique. Un programme comme l'Executive MBA en Management et Data Science conjoint ESLSCA & IAE Paris gagnerait à mettre davantage l'accent sur cette discipline en lui accordant plus de temps dans le programme. Au vu de sa grande richesse et de ses nombreux démembrements, la gouvernance Data et IA pourrait même faire l'objet d'un module à part entière, spécifiquement réparti entre gouvernance data et gouvernance IA, avec les processus, rôles et outils assortis.

Notre étude est, comme toute œuvre humaine, imparfaite et faillible. Elle reste donc ouverte aux critiques, remarques et suggestions, en vue de son amélioration. Les limites observées ainsi que l'enthousiasme manifesté dans les questionnaires vis-à-vis du sujet (87,5%) montrent clairement qu'il serait intéressant de l'approfondir dans le cadre d'un projet de recherche plus poussé et bien plus pratique. Cela pourrait faire l'objet d'une thèse de doctorat, éventuellement.

Références

Bibliographie

Asaph, L. Y. (2022). *La traduction automatique neuronale face au traducteur humain : une étude sur la post-édition* [Mémoire de master, Institut supérieur de Traduction, d'Interprétation et de Communication].

Asgarova, M., & Sadagat, B. (2024). L'impact des avancées technologiques et de l'IA sur l'évolution linguistique et l'emprunt lexical. *Euro-Global Journal of Linguistics and Language Education*, *2*(2), 15-23. https://doi.org/10.69760/egjlle.250002

Bénard, M., Kübler, N., Mestivier, A., Minder, J., & Zhu, L. (2024). *Étude des Protocoles d' Évaluation Humaine pour la Traduction de Documents* (Livrable D4-1.1). Projet ANR MaTOS. https://hal.science/hal-04700009 (pp. 442-454). https://hal.science/hal-05124900

Challapally, A., Pease, C., Raskar, R., & Chari, P. (2025). *The GenAI divide: State of AI in business 2025* (Version 0.1) [Report]. Massachusetts Institute of Technology, Project NANDA.

Collibra. (2023). *How to become a data governance expert*.

Collibra. (2024). *AI governance: An essential element for successful AI*.

DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (2nd ed.). Technics Publications.

de Fornel, M. (2002). Le destin d'un argument : le relativisme linguistique de Sapir-Whorf. In M. de Fornel & J.-C. Passeron (éds.), *L'argumentation* (1-). Éditions de l'École des hautes études en sciences sociales.

Dehaene, S. (2020). *L'influence du langage et des symboles sur la perception et la cognition : Cours n°1, Introduction aux théories du relativisme linguistique et culturel* [Cours]. Collège de France, Paris, France.

European Commission. (2020). *A European strategy for data* (COM(2020) 66 final).

Fasquelle, P. (2023). les softs Skills pour les rôles Agiles: Développez vos compétences personnelles et relationnelles. (n.p.): Books on Demand.

Fiorini, S. (2020). L'intelligence artificielle au défi du multilinguisme : Usages et perspectives de la traduction automatique neuronale dans la communication scientifique. *Arabesques*, (100), 73-76.

Fiorini, S. (2022). L'intelligence artificielle au défi du multilinguisme : usages et perspectives de la traduction automatique neuronale dans la communication scientifique. I2D - Information, données & documents, 1(1), 73-76. https://doi.org/10.3917/i2d.221.0073.

Fleisig, E., Smith, G., Bossi, M., Rustagi, I., Yin, X., & Klein, D. (2024). Linguistic Bias in ChatGPT: Language Models Reinforce Dialect Discrimination. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 13541–13564. Association for Computational Linguistics.

Haun, D. B. M., Rapold, C. J., Janzen, G. et Levinson, S. C. (2011). Plasticité de la cognition spatiale humaine : Spatial language and cognition covary across cul*tures. Co*gnit*i*on, 119(1), 70-80. https://doi.org/10.1016/j.cognition.2010.12.009

Hayler, A. (2025). *Data governance in the age of AI*. Bloor Research.

Helm, P., Bella, G., Koch, G., & Giunchiglia, F. (2023). *Diversity and Language Technology: How Techno-Linguistic Bias Can Cause Epistemic Injustice* [Prépublication]. arXiv. https://arxiv.org/abs/2307.13714

Hickmann, M. (2009). 3. Relativité linguistique et développement : la représentation de l'espace. In M. Kail, M. Fayol, & M. Hickmann (éds.), *Apprentissage des langues* (1-). CNRS Éditions. https://doi.org/10.4000/books.editionscnrs.5962

Informatica. (2024). *Guide du programme de gouvernance des données et de l'IA*.

Iroetugo, E. R., & Anyawuike, O. S. O. (2024). L'impact de la traduction par IA sur les rencontres et relations interculturelles a l'échelle mondiale. *Multidisciplinary Journal of Law, Education and Humanities (MJLEH)*, *1*(2), 128-134.

Jenks, C. J. (2024). Communicating the cultural other: trust and bias in generative AI and large language models. *Applied Linguistics Review*. Publication en ligne anticipée. https://doi.org/10.1515/applirev-2024-0196

Laugier, S. (1996). Relativité linguistique, relativité anthropologique. *Histoire Épistémologie Langage, 18*(2), 45–73. https://doi.org/10.3406/hel.1996.2460

Leclercq, P., & Benazzo, S. (2021). La relativité linguistique et l'acquisition du langage. In P. Leclercq, A. Edmonds, & E. Sneed-German (Éds.), *Introduction à l'acquisition des langues étrangères*. De Boeck.

Leduc, C. (2022). L'enchantement de la machine : la nature systémique du néo-matérialisme. Cahiers Société, (4), 95–114. https://doi.org/10.7202/1098601ar

Liu, Z. (2024). Cultural Bias in Large Language Models: A Comprehensive Analysis and Mitigation Strategies. *Journal of Transcultural Communication*. Publication en ligne anticipée. https://doi.org/10.1515/jtc-2023-0019

Loffler-Laurian, A.-M. (1990). La traduction automatique. Bref historique. In M. Ballard (éd.), *La traduction plurielle* (1-). Presses universitaires du Septentrion. https://doi.org/10.4000/books.septentrion.124565

Loffler-Laurian, A.-M. (1996). Chapitre II. Typologie des erreurs. In *La traduction automatique* (1-). Presses universitaires du Septentrion. https://doi.org/10.4000/books.septentrion.74889

Loock, R., Moulard, N., & Pacinella, Q. (2025). MT or not MT? Do translation specialists know a machine-translated text when they see one?. *20th Machine Translation Summit*

Mery, M. (2022). Négociation complexe: Manuel de résolution de conflits difficiles. (n.p.): Eyrolles.

Nakhlé, M. (2023). L'évaluation de la traduction automatique du caractère au document : un état de l'art. Dans *18e Conférence en Recherche d'Information et Applications -- 16e Rencontres Jeunes Chercheurs en RI -- 30e Conférence sur le Traitement Automatique des Langues Naturelles -- 25e Rencontre des Étudiants Chercheurs en Informatique pour le Traitement Automatique des Langues* (pp. 143–159). https://hal.science/hal-04130237

Nielsen, O. B. (2017). A comprehensive review of data governance literature. *Selected Papers of the IRIS, Issue Nr 8*. Otto, B. (2011). *A morphology of the organisation of data governance*. ECIS 2011 Proceedings.

Nord, C. (1991). *Text analysis in translation: Theory, method, and didactic application of a model for translation-oriented text analysis* (C. Nord & P. Sparrow, Trans.). Rodopi.

Pascale Leclercq, Sandra Benazzo. La relativité linguistique et l'acquisition du langage.. P. Leclercq, A. Edmonds & E. Sneed-German (éds.). Introduction à l'acquisition des langues étrangères., De Boeck, 2021.

Rossi, C. (2013). Chapitre 5. Relativité linguistique et innéité : ennemies d'un jour ? Dans D. Forest L'innéité aujourd'hui : Connaissances scientifiques et problèmes philosophiques (p. 101-116). Éditions Matériologiques. https://doi.org/10.3917/edmat.fores.2013.01.0101.

RWS. (2021). *Machine translation post-editing*.

Sikka, K., Kucharlapati, G. V., & Vaishnapu, M. (2024). *Lost in AI Translation: Ethical Analysis of Cultural Bias in Language Models and Digital Assistants*. University of Florida, Department of Computer and Information Science and Engineering. https://www.researchgate.net/publication/386540362_Lost_in_AI_Translation_Ethical_Analysis_of_Cultural_Bias_in_Language_Models_and_Digital_Assistants

Steinert, C. V., & Kazenwadel, D. (2024). How user language affects conflict fatality estimates in ChatGPT. *Journal of Peace Research*. Publication en ligne anticipée. https://doi.org/10.1177/00223433241279381

Tao, Y., Viberg, O., Baker, R. S., & Kizilcec, R. F. (2024). Cultural bias and cultural alignment of large language models. *PNAS Nexus*, *3*(9), pgae346. https://doi.org/10.1093/pnasnexus/pgae346

The Decision Lab. (2023). L'hypothèse de Whorf. The Decision Lab. Retrieved June 18, 2025, from https://thedecisionlab.com/languages/fr-ca/reference-guide/linguistics/the-whorf-hypothesis

The European Parliament and the Council of the European Union. (2022). *Regulation (EU) 2022/868 on European data governance (Data Governance Act)*. Official Journal of the European Union, L 152/1.

The European Parliament and the Council of the European Union. (2023). *Regulation (EU) 2023/2854 on harmonised rules on fair access to and use of data (Data Act)*. Official Journal of the European Union, L 2023/2854.

The European Parliament and the Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union, L 2024/1689.

Triboulet, B. (2022). *Biais de genre dans la traduction automatique neuronale : étude des facteurs potentiels pour la traduction des noms de métiers* [Mémoire de master, Université de Genève]. Archive ouverte UNIGE. https://archive-ouverte.unige.ch/unige:164472

Urman, A., & Makhortykh, M. (2023). *The Silence of the LLMs: Cross-Lingual Analysis of Political Bias and False Information Prevalence in ChatGPT, Google Bard, and Bing Chat* [Prépublication]. OSF Preprints. https://doi.org/10.31219/osf.io/usvqt

Venturino, M. (2023). Guide du product management: La référence de tous les product managers. (n.p.): Eyrolles.

Wende, K. (2007). *A model for data governance - Organising accountabilities for data quality management*. ACIS 2007 Proceedings.

Sites

https://bigmedia.bpifrance.fr/nos-dossiers/ia-ethique-et-inclusive-quels-enjeux-et-defis-pour-les-entreprises

https://bigmedia.bpifrance.fr/nos-dossiers/ia-ethique-et-inclusive-quels-enjeux-et-defis-pour-les-entreprises

https://blog.pipplet.com/openai-linguistic-diversity-bias-reduction-ai-language-testing

https://magazine.mindplex.ai/post/ais-linguistic-bias-a-silent-architect-of-cultural-marginalization

https://mesinfos.fr/75000-paris/ia-et-biais-algorithmiques-vers-une-injustice-programmee-216198.html

https://newsroom.haas.berkeley.edu/minority-homebuyers-face-widespread-statistical-lending-discrimination-study-finds/

https://presse.inserm.fr/biais-cognitifs-dans-le-soin-comment-lia-generative-pourrait-aider-a-ameliorer-la-prise-en-charge/70072/

https://privacysos.org/blog/five-fast-facts-from-the-federal-study-of-demographic-bias-in-facial-recognition/

https://theconversation.com/ia-et-credit-comment-eviter-que-les-machines-ne-contribuent-a-reproduire-nos-biais-sociaux-252152

https://venturebeat.com/ai/large-language-models-exhibit-significant-western-cultural-bias-study-finds/

https://www.aclu.org/news/privacy-technology/how-is-face-recognition-surveillance-technology-racist

https://www.aclu.org/news/privacy-technology/wrongfully-arrested-because-face-recognition-cant-tell-black-people-apart

https://www.bfmtv.com/tech/intelligence-artificielle/debiaiser-l-ia-comment-les-algorithmes-se-nourrissent-de-nos-prejuges_AV-202502110586.html

https://www.datarobot.com/newsroom/press/datarobots-state-of-ai-bias-report-reveals-81-of-technology-leaders-want-government-regulation-of-ai-bias/

https://www.er-tim.fr/criteres-evaluer-qualite-outil-traduction-automatisee.html

https://www.forbes.com/sites/andreahill/2025/08/21/why-95-of-ai-pilots-fail-and-what-business-leaders-should-do-instead/

https://www.forbes.com/sites/bernardmarr/2022/09/30/the-problem-with-biased-ais-and-how-to-make-ai-better/?sh=287c569c4770

https://www.hubinstitute.com/temoignages-triple-acceleration/chaffika-chettaoui-axa

https://www.inria.fr/fr/biais-allocation-algorithmes-ia-equitable

https://www.ladn.eu/tech-a-suivre/biais-algorithmiques-limpossible-neutralite-de-l-ia/

https://www.sciencesetavenir.fr/high-tech/intelligence-artificielle/les-biais-de-l-intelligence-artificielle-amplifient-nos-propres-biais_183193

https://www.solutions-numeriques.com/avis-dexpert-de-la-gouvernance-des-donnees-a-la-continuite-de-services-comment-assurer-votre-souverainete-numerique/

Annexes

Toutes les annexes qui ont servi à élaborer le présent travail sont disponibles via le lien Google Drive ci-après :

https://drive.google.com/drive/folders/1JPrZeDfuGyzLOVLGA9si_NZ4r6fOkBIM?usp=drive_link